

# SÉRIES STATISTIQUES

## A DEUX VARIABLES


→ Il s'agit d'étudier simultanément DEUX caractères d'une "population".

### I. NUAGE DE POINTS

Exemple: Une grande surface s'intéresse au lien existant entre ses dépenses de publicité et son CA.

Elle réalise les observations suivantes:

Dépenses de pub (k€) $x_i$	0,5	2	2,9	4,5	5,6
CA (k€) $y_i$	35	37	75	92	90



↳ L'ensemble des points  $M_i$  de coordonnées  $(x_i, y_i)$  constitue le NUAGE de points représentant la série statistique.

Une fois le nuage dessiné, on cherche à trouver une fonction  $f$  telle que la courbe d'équation  $y = f(x)$  passe "le plus près possible" des points du nuage → c'est le problème de l'ADJUSTEMENT



Ici, il semble qu'on puisse approcher le nuage par une droite (car le nuage est aplati / allongé) → Ajustement AFFINE

Mais on peut avoir aussi un ajustement parabolique, logarithmique, exponentiel ... ou ne pas en avoir!

⚠ Corrélation  $\neq$  causalité.  
(= évoluer conjointement)

Définition: On appelle POINT MOYEN d'un nuage de  $n$  points  $\Pi$ , de coordonnées  $(x_i, y_i)$ , le point  $G$  de coordonnées

$$(x_G, y_G) = (\bar{x}, \bar{y})$$

où  $\bar{x}$  = moyenne des  $x_i$

$\bar{y}$  = moyenne des  $y_i$

→ à déterminer à la calculatrice

ex précédent:  $G: (3,1; 65,8)$

## II. AJUSTEMENT AFFINE

### A. Méthodes graphiques

#### 1) Ajustement "à la règle"

→ Imprécis  $\Rightarrow$  Non utilisé!

#### 2) Méthode de MAYER

Non utilisé! Principe:

→ on divise le nuage en deux "sous-nuages"

→ on calcule les 2 points moyens  $G_1$  et  $G_2$

→ La droite de Mayer est celle qui relie  $G_1$  et  $G_2$

$(G_1, G_2)$  a pour équation  $y = ax + b$

avec  $a = \frac{y_{G_2} - y_{G_1}}{x_{G_2} - x_{G_1}}$  et  $b$  obtenue en remplaçant les coordonnées de  $G_1$  et  $G_2$

Cette méthode manque aussi de précision.




## B. Méthode des moindres carrés

### 1. Principe

→ on cherche la droite qui pourrait remplacer "au mieux" le nuage de points, c'est-à-dire la + proche possible de tous les points.

Def: On appelle Droite de RÉGRESSION de  $y$  en  $x$  la droite  $D$  telle que la somme  $\sum_{i=1}^n M_i P_i^2 = \sum_{i=1}^n [y_i - (ax_i + b)]^2$  soit minimale.



$M_i$  = observations, de coordonnées  $(x_i, y_i)$

$P_i$  = Points théoriques, de coord  $(x_i; ax_i + b)$

→ Distance entre  $M_i$  et  $P_i$   
 $= M_i P_i$

→ Comme certaines sont < 0, on prend les carrés

→ on veut les distances les + petites = les MOINDRES CARRÉS (d'où le nom de la méthode)

Beaucoup + rare:

Def: On appelle Droite de régression de  $x$  en  $y$  la droite  $D'$  telle que la somme  $\sum_{i=1}^n M_i Q_i = \sum_{i=1}^n [x_i - (ay_i + b)]^2$  soit minimale

(Principe inverse: on veut minimiser les écarts horizontaux)

### 2. Equation de la droite de régression

On montre que la droite de régression  $D$  de  $y$  en  $x$  a pour équation  $y = ax + b$  avec  $a = \frac{\sigma_{xy}}{(\sigma_x)^2} = \frac{\text{Covariance de } x \text{ et } y}{\text{Variance de } x}$

et  $\bar{y} = a\bar{x} + b$ .

**EN PRATIQUE,  $a$  et  $b$  sont DONNÉS par le menu statistique de la calculatrice.** ( $\Rightarrow$  formules inutiles!)

Pour la régression de  $x$  en  $y$ : équation  $x = a'y + b'$  → on inverse  $x$  et  $y$  dans la calculatrice.



Dans l'exemple au début du cours  $a \approx 12,77$  et  $b \approx 26,22$ ,  
donc on a  $y = 12,77x + 26,22$ .

## C - Coefficient de corrélation linéaire

→ Il permet d'apprécier la qualité d'un ajustement affine.  
Un tel ajustement est justifié lorsque le nuage est aplati/allongé.

On a 
$$r = \frac{\overline{xy}}{\overline{x} \overline{y}}$$

EN PRATIQUE, il est donné  
par la calculatrice.

Propriétés:

- $r \in \mathbb{R}$ , il est du même signe que  $a$  (si  $r < 0$ , corrélation négative, la droite "descend", et si  $r > 0$ , corrélation positive, et la droite "monte")



- On a TOUJOURS  $-1 \leq r \leq 1$
- Il existe une "bonne" corrélation entre  $x$  et  $y$  lorsque  $|r|$  est "suffisamment" voisine de 1.
- $r^2 = aa'$

Remarques:

- selon les secteurs, on choisit pour quelles valeurs de  $r$  la corrélation est jugée suffisante pour effectuer un ajustement affine par les moindres carrés (c'est à dire à la calculatrice).
- Forte corrélation  $\neq$  causalité.